



Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Inteligencia Artificial

Sistema de visión artificial para el registro geométrico y vectorización de contornos en operaciones de impresión y corte con láser CNC

Trabajo Fin de Estudios

presentado por: Bryan Guillermo Guananga Rodríguez

Dirigido por: María Flores Ceballos

Ciudad: Riobamba

Fecha: agosto de 2026

Índice de Contenidos

1. Introducción	1
1.1. Motivación y contexto del problema	1
1.2. Planteamiento del problema	2
1.3. Aporte y alcance del trabajo	4
1.4. Estructura de la memoria	5
2. Contexto y estado del arte	6
2.1. Contexto productivo	6
2.1.1. Fabricación personalizada de toppers	6
2.1.2. Flujo CAD/CAM y sistema de coordenadas de trabajo	6
2.1.3. Captura con cámara de consumo	7
2.1.4. Dificultades visuales de la escena	7
2.2. Fundamentos geométricos	7
2.2.1. Calibración y distorsión de cámara	9
2.2.2. Homografía y rectificación planar	9
2.3. Segmentación mediante visión clásica	10
2.4. Aprendizaje automático para segmentación	10
2.4.1. Random Forest como clasificador por píxel	11
2.4.2. Redes convolucionales y alternativas consideradas	12
2.4.3. Modelos fundacionales y SAM 2	12
2.5. Métricas de segmentación	13
2.6. Vectorización y geometría fabricable	14
2.7. Síntesis crítica	14
3. Objetivos	16
3.1. Objetivo general	16
3.2. Objetivos específicos	16
3.3. Impacto esperado	17
4. Identificación de requisitos	18
4.1. Requisitos funcionales	18
4.2. Requisitos no funcionales	19

4.3. Criterios de aceptación del prototipo	20
5. Metodología	21
5.1. Diseño general del estudio	21
5.2. Montaje y adquisición de imágenes reales	21
5.3. Construcción del conjunto sintético	23
5.4. Referencia canónica del dominio real	26
5.5. Línea base de visión clásica	27
5.6. Random Forest y optimización de hiperparámetros	27
5.6.1. Características y muestreo	27
5.6.2. Búsqueda agrupada	28
5.7. SAM 2 y selección de prompts	29
5.8. Métricas y análisis	29
5.9. Trazabilidad y reproducibilidad	30
6. Descripción de la herramienta software desarrollada	31
6.1. Arquitectura general	31
6.2. Organización del código	31
6.3. Carga, marcadores y rectificación	33
6.4. Detección del sistema de coordenadas de trabajo	33
6.5. Localización y segmentación con SAM 2	34
6.6. Contornos y exportación DXF	34
6.7. Interfaz gráfica	36
6.8. Verificación de la integración	36
7. Evaluación	38
7.1. Optimización y selección de Random Forest	38
7.2. Selección de prompts para SAM 2	39
7.3. Resultados en el dominio sintético	40
7.4. Transferencia a capturas reales	41
7.5. Repetibilidad del registro geométrico	42
7.6. Validación de la cadena software	45
7.7. Limitaciones	45

8. Conclusiones y trabajo futuro	46
8.1. Conclusiones	46
8.2. Cumplimiento de los objetivos	47
8.3. Aportes del trabajo	48
8.4. Trabajo futuro	48
 ANEXO A. Repositorio y reproducibilidad	 50
A.1. Estructura principal	50
A.2. Preparación del entorno	50
A.3. Modelos utilizados	51
A.4. Comandos de reproducción	51
A.5. Ejecución de la herramienta	52
A.6. Publicación	52
Referencias	53

Índice de Figuras

Figura 1.	Comparación entre el flujo manual actual y el flujo propuesto para la fabricación de toppers en Innokey.	3
Figura 2.	Relación entre la captura visual, la geometría CAD y la trayectoria de fabricación CAM en el flujo propuesto.	4
Figura 3.	Dificultades visuales presentes en las capturas reales.	8
Figura 4.	Rectificación de la hoja mediante correspondencias entre los marcadores detectados y el plano canónico A4.	10
Figura 5.	Funcionamiento del Random Forest por píxel, desde la extracción de características hasta la agregación de los árboles y la formación de la máscara.	11
Figura 6.	Arquitectura funcional de SAM 2 para una imagen estática condicionada mediante cajas geométricas.	13
Figura 7.	Diseño experimental con separación por lámina y bloqueo del conjunto de prueba hasta cerrar las decisiones de modelo y prompt.	22
Figura 8.	Montaje utilizado para capturar la hoja A4 adherida al MDF dentro de la cortadora láser.	22
Figura 9.	Seis capturas rectificadas representativas del conjunto real.	24
Figura 10.	Ocho ejemplos del conjunto de hojas sintéticas.	25
Figura 11.	Arquitectura híbrida implementada. La localización clásica aporta cajas y SAM 2 genera la máscara que alimenta la vectorización.	31
Figura 12.	Ejecución completa de la captura 20 con SAM 2.	35
Figura 13.	Interfaz gráfica con SAM 2 como segmentador operativo y revisión de la salida vectorial.	36
Figura 14.	IoU medio de las cinco estrategias de prompt de SAM 2 sobre el conjunto sintético de validación.	39
Figura 15.	Comparación de IoU, Dice y Boundary F1 en las seis hojas sintéticas de prueba.	40

Figura 16.	Comparación visual de la referencia y las predicciones sobre la captura real 13.	43
Figura 17.	Cambio del IoU medio entre prueba sintética y capturas reales. . .	44

Índice de Tablas

Tabla 1.	Particiones utilizadas en el protocolo experimental.	26
Tabla 2.	Módulos principales de la herramienta.	32
Tabla 3.	Selección de Random Forest sobre las seis hojas completas de validación.	38
Tabla 4.	Resultados sobre las seis hojas sintéticas de prueba.	40
Tabla 5.	Resultados sobre trece capturas rectificadas de una misma hoja real.	41
Tabla 6.	Repetibilidad del registro por topper en capturas con WCS válido.	44
Tabla 7.	Cumplimiento de los objetivos específicos.	47
Tabla 8.	Identificación de modelos y checkpoints.	51

Resumen

Este Trabajo Fin de Máster desarrolla un sistema de inteligencia artificial aplicado a visión artificial para registrar una hoja adhesiva impresa, segmentar sus diseños y convertir las siluetas en trayectorias de corte láser CNC. El caso de aplicación procede de Innokey, un taller de Riobamba donde los toppers personalizados se fabrican uniendo de forma manual una impresión adhesiva y una base rígida de MDF o acrílico. Esa operación puede introducir desplazamientos visibles y reprocesos. El flujo propuesto invierte la secuencia: la hoja completa se adhiere primero al soporte, una cámara registra la escena y el software calcula el contorno que debe seguir la máquina.

La herramienta combina rectificación por homografía, detección del sistema de coordenadas de trabajo y segmentación neuronal con SAM 2 Hiera Tiny. La visión clásica se conserva como línea base y como localizador aproximado de cajas, pero la máscara final que alimenta la extracción de contornos y la exportación DXF procede de SAM 2. También se estudió un Random Forest por píxel mediante búsqueda de hiperparámetros, validación agrupada y selección del umbral sobre láminas completas. Los experimentos utilizaron 48 hojas sintéticas separadas en 36 de entrenamiento, 6 de validación y 6 de prueba, además de 13 capturas rectificadas de una misma lámina real.

Los resultados muestran una diferencia clara entre dominios. En prueba sintética, Random Forest obtuvo un IoU medio de 0,9902, SAM 2 alcanzó 0,9153 y la línea clásica 0,9016. En las capturas reales, la visión clásica mantuvo el mejor IoU, con 0,9787, mientras que SAM 2 obtuvo 0,9536 y conservó las ocho instancias correctas en todas las imágenes. Random Forest descendió a 0,2877, lo que evidencia la brecha entre el banco sintético y las condiciones del taller. A pesar de no superar a la línea base real, SAM 2 ofreció contornos estables y quedó integrado como motor de segmentación de la interfaz. Una ejecución completa con referencia WCS válida generó ocho contornos y un archivo DXF no vacío.

Palabras clave. Visión artificial, Segmentación, Vectorización, Random Forest, SAM.

Abstract

This Master’s Thesis develops an artificial intelligence system for computer vision to register a printed adhesive sheet, segment its designs and convert their silhouettes into CNC laser-cutting paths. The application stems from Innokey, a small workshop in Riobamba where custom cake toppers are produced by manually joining an adhesive print to a rigid MDF or acrylic base. That operation may introduce visible offsets and rework. The proposed workflow changes the sequence: the complete sheet is first attached to the substrate, a camera records the scene and the software estimates the contour that the machine must follow.

The tool combines homography-based rectification, work coordinate system detection and neural segmentation with SAM 2 Hierarchical Tiny. Classical computer vision is retained as a baseline and as a coarse box localizer, while the final mask passed to contour extraction and DXF export is generated by SAM 2. A pixel-wise Random Forest was also studied through hyperparameter search, grouped validation and full-sheet threshold selection. The experiments used 48 synthetic sheets split into 36 training, 6 validation and 6 test samples, together with 13 rectified captures of one physical sheet.

The results reveal a marked domain difference. On the synthetic test set, Random Forest achieved a mean IoU of 0.9902, SAM 2 reached 0.9153 and the classical baseline obtained 0.9016. On real captures, classical vision remained the strongest method with an IoU of 0.9787, while SAM 2 obtained 0.9536 and preserved the correct eight instances in every image. Random Forest fell to 0.2877, exposing the gap between synthetic training data and workshop conditions. Although SAM 2 did not outperform the real classical baseline, it produced stable contours and was integrated as the segmentation engine of the user interface. A complete run with a valid WCS reference generated eight contours and a non-empty DXF file.

Keywords. Computer vision, Segmentation, Vectorization, Random Forest, SAM.

1. Introducción

Un topper de pocos centímetros puede perderse por completo si el láser no sigue la silueta impresa. El error puede ser pequeño en términos absolutos, pero resulta visible de inmediato en una pieza decorativa. Ese problema cotidiano resume el punto de partida de este trabajo. La fabricación personalizada combina diseños variables, lotes cortos y una fuerte dependencia de la preparación manual. En esas condiciones, la calidad no depende solo de la velocidad de la máquina. También depende de que la impresión y la trayectoria de corte coincidan cada vez que cambia el pedido.

La inteligencia artificial ha ampliado el alcance de la inspección y el guiado visual en la industria. Los modelos de aprendizaje pueden encontrar patrones que resultarían difíciles de expresar mediante reglas fijas, mientras que la visión artificial aporta las transformaciones geométricas necesarias para medir y actuar sobre una escena. En fabricación, ambas perspectivas suelen convivir. Existen sistemas que combinan procesamiento de imagen y clasificadores para control de calidad (Ozkan, 2025), y otros que utilizan segmentación neuronal para medir regiones de interés durante el proceso productivo (Loganathan, Andersson, y Patel, 2026). Esto no significa que un modelo de inteligencia artificial sea siempre superior. Su utilidad depende de los datos, del cambio entre el laboratorio y la planta, de los recursos de cómputo y de la forma en que se integra a la operación real.

El presente TFM se sitúa precisamente en ese cruce. Se desarrolla una herramienta software para registrar una hoja impresa, segmentar los toppers mediante un modelo neuronal preentrenado y convertir sus contornos en geometría vectorial. A la vez, se conserva una línea base de visión clásica y se estudia un Random Forest por píxel. La comparación permite observar qué ocurre cuando los métodos se enfrentan a datos sintéticos controlados y, después, a fotografías tomadas dentro de un taller.

1.1. Motivación y contexto del problema

El caso de aplicación procede de Innokey, una empresa de Riobamba dedicada a productos personalizados mediante impresión digital y corte láser de CO₂. Entre sus pedidos habituales se encuentran los denominados *toppers* para pasteles. En este trabajo, se entiende por *topper* una pieza decorativa que combina una imagen adhesiva impresa con una base rígida de MDF o acrílico. La percepción de calidad depende de la coincidencia entre

ambas capas. Un giro leve o un desplazamiento lateral puede dejar visible la base y obligar a repetir la pieza.

El proceso convencional separa dos operaciones que luego deben coincidir. Primero se imprime la hoja adhesiva y se recortan las siluetas en un plóter de cuchilla. En paralelo, las bases rígidas se cortan en la máquina láser. Finalmente, el operario pega cada adhesivo sobre su soporte. Esa última unión depende de la habilidad manual y concentra una parte importante de la variabilidad.

La alternativa propuesta cambia la secuencia. La hoja impresa se adhiere completa sobre el MDF o el acrílico antes del corte. A continuación, una cámara registra la zona de trabajo y el software calcula las trayectorias a partir de la posición real de la impresión. De esta forma, la geometría no se prepara para un material idealmente colocado. Se obtiene de la escena que la máquina tiene delante en ese momento.

La Figura 1 muestra la diferencia principal. En el flujo actual, la impresión y el soporte se encuentran al final del proceso. En el flujo planteado, se unen al comienzo y la visión artificial se encarga de recuperar el contorno sobre el material ya laminado. El beneficio esperado no se limita al tiempo de preparación. La prioridad es reducir la variabilidad del pegado y evitar reprocesos por desalineaciones visibles.

1.2. Planteamiento del problema

Una cortadora láser CNC ejecuta trayectorias vectoriales. Cuando el material está en blanco, el archivo digital puede dictar la geometría completa. El escenario cambia cuando la plancha ya contiene una impresión física. En ese caso no basta con importar el vector original. Es necesario reconocer la posición real de la hoja, corregir la perspectiva de la fotografía, identificar el origen de trabajo y separar los bordes externos de los detalles internos del dibujo.

El problema de investigación puede formularse así: ¿cómo construir una herramienta de inteligencia artificial capaz de transformar una captura de una hoja adhesiva ya colocada sobre el soporte en contornos vectoriales registrados respecto al sistema de coordenadas de trabajo del láser? La respuesta debe ser técnicamente reproducible y, al mismo tiempo, lo bastante sencilla para un entorno de pequeña empresa.

La dificultad no reside en una sola etapa. La cámara puede cambiar ligeramente de posición, la hoja puede aparecer rotada, las sombras del cabezal atraviesan la escena y

Flujo actual y flujo propuesto para toppers personalizados en Innokey
Caso de estudio: adhesivo impreso sobre soporte de acrílico o MDF y corte en láser CNC




Figura 1: Comparación entre el flujo manual actual y el flujo propuesto para la fabricación de *toppers* en Innokey. El bloque izquierdo representa la secuencia vigente, donde el adhesivo y la base se cortan por separado y se unen manualmente. El bloque derecho muestra la alternativa estudiada, que adhiere primero la hoja completa, captura su posición y calcula los contornos antes del corte láser. La franja inferior resume la diferencia esperada en alineación, reprocesos y repetibilidad. Las flechas indican el orden de las operaciones y permiten localizar el punto en el que se incorpora la visión artificial.

algunos diseños contienen colores pastel próximos al blanco. Además, el borde exterior que interesa para cortar convive con ojos, pliegues, brillos y otros trazos impresos que no deben convertirse en trayectorias. La herramienta necesita resolver estos problemas sin perder la referencia física de la máquina.




Figura 2: Relación entre la captura visual, la geometría CAD y la trayectoria de fabricación CAM en el flujo propuesto.

La Figura 2 sitúa la visión artificial dentro de la cadena CAD/CAM. La captura sigue siendo una imagen rasterizada, pero la máquina necesita curvas expresadas en unidades físicas. El software debe enlazar ambos dominios y bloquear la exportación cuando no exista una referencia geométrica fiable.

1.3. Aporte y alcance del trabajo

El TFM se plantea como desarrollo software aplicado. Su aporte principal es una herramienta modular que integra registro geométrico, segmentación con SAM 2, extracción de contornos y exportación DXF. La visión clásica se utiliza para detectar marcadores, rectificar la hoja, localizar el sistema de coordenadas y proponer cajas aproximadas. SAM 2 genera la máscara final de cada topper. Esa misma máscara alimenta la vectorización y no existe una sustitución silenciosa por el método clásico si el modelo neuronal falla.

La comparación experimental forma una segunda contribución. Se evalúan la línea base clásica, Random Forest y SAM 2 sobre un conjunto sintético con particiones independientes. Los tres se contrastan también en trece capturas de una misma lámina real. El objetivo no es demostrar por anticipado que la inteligencia artificial siempre gana. Se busca establecer con evidencia qué método funciona mejor en cada dominio y qué dependencias aparecen cuando el modelo sale del entorno controlado.

El alcance termina en la validación computacional del software y en la generación de un DXF operativo. No se declara cerrada la validación física del corte. Para hacerlo sería necesario fabricar un lote completo, medir el borde impreso frente al borde cortado y comparar el reproceso con el flujo manual. Esta delimitación evita confundir una trayectoria

correctamente calculada con una precisión mecánica que todavía no se ha medido.

1.4. Estructura de la memoria

La memoria se organiza de la siguiente manera:

- El Capítulo 2 describe el entorno de Innokey y revisa los fundamentos de registro, segmentación, inteligencia artificial y vectorización.
- El Capítulo 3 presenta el objetivo general y los objetivos específicos.
- El Capítulo 4 delimita los requisitos funcionales y no funcionales de la herramienta.
- El Capítulo 5 explica el diseño experimental, los datos, la optimización de Random Forest y la selección de prompts de SAM 2.
- El Capítulo 6 describe la arquitectura del software y el uso de SAM 2 dentro de la interfaz.
- El Capítulo 7 presenta los resultados, la comparación entre métodos y las limitaciones observadas.
- El Capítulo 8 relaciona los resultados con los objetivos y plantea el trabajo futuro.
- El ANEXO A documenta el repositorio, su estructura y las instrucciones de reproducción.

2. Contexto y estado del arte

Este capítulo sitúa el problema dentro del proceso productivo y reúne los fundamentos que sostienen la solución. La revisión avanza desde el flujo CAD/CAM y la geometría de la captura hasta los métodos de segmentación. Después aborda Random Forest, los modelos fundacionales de segmentación y la conversión de máscaras a trayectorias de corte.

2.1. Contexto productivo

El contexto productivo determina qué información debe recuperar la cámara y qué salida necesita la máquina. Por ello, antes de revisar los algoritmos conviene describir la pieza, el flujo CAD/CAM y las condiciones reales de captura.

2.1.1. Fabricación personalizada de toppers

La fabricación por encargo obliga a preparar la máquina muchas veces para lotes pequeños. Cada pedido puede incluir formas distintas, tamaños variables y materiales parcialmente aprovechados. En Innokey, los toppers muestran con claridad esa variación. Los diseños parten de imágenes o ideas entregadas por los clientes y luego se corrigen, depuran o redibujan antes de imprimirlos sobre una lámina adhesiva.

El punto crítico aparece al integrar la impresión y la base rígida. El plóter recorta la capa adhesiva y el láser corta el MDF o el acrílico en operaciones separadas. Más tarde, el operario debe hacer coincidir cada par de piezas. La diversidad de formas vuelve poco prácticas las guías rígidas y una desviación pequeña puede dejar visible el soporte.

2.1.2. Flujo CAD/CAM y sistema de coordenadas de trabajo

Las cortadoras láser CNC trabajan con trayectorias vectoriales planas. La geometría suele prepararse en un entorno de diseño asistido por computador (CAD) y después pasa al software de fabricación asistida por computador (CAM), donde se establecen velocidad, potencia y orden de corte. Cuando la pieza ya contiene una impresión, la visión artificial puede observar su posición real y convertirla en geometría compatible con ese flujo (Bhandari y Manandhar, 2023; Jednorog, 2025; Khafagy, Eltaib, y Abo-Shanab, 2025).

Conviene distinguir el sistema de coordenadas de máquina del sistema de coordenadas de trabajo. El primero pertenece a la estructura de la cortadora y a sus finales de carrera.

El segundo, denominado WCS por *Work Coordinate System*, lo define el operario según el material y el aprovechamiento de la mesa. En una máquina de aproximadamente 130×90 cm, ese origen puede cambiar entre pedidos. Por este motivo, la herramienta no depende de una plantilla fija. Utiliza una marca en forma de L grabada por el propio láser sobre una zona libre de la hoja.

2.1.3. Captura con cámara de consumo

La región de trabajo se limita a una hoja A4 adherida al soporte. La restricción concentra los píxeles de la cámara en el área que realmente contiene los diseños y permite trabajar a una escala nominal de 10 px/mm. Cubrir toda la mesa exigiría alejar la cámara y reduciría el detalle disponible para los bordes finos.

La captura se realiza con un teléfono inteligente montado en la compuerta superior. El soporte es removible y no garantiza una posición idéntica entre sesiones. La hoja incorpora cuatro marcadores negros que permiten estimar su orientación y rectificar la perspectiva. Esta decisión reduce el coste del montaje y hace posible reproducirlo sin una cámara industrial fija.

2.1.4. Dificultades visuales de la escena

La impresión sobre fondo blanco facilita parte de la separación, pero no elimina la dificultad. Los diseños contienen tonos pastel, zonas blancas internas, degradados y trazos oscuros que no pertenecen al borde de corte. La iluminación del taller añade sombras, reflejos y cambios de balance de blancos. También pueden aparecer en la captura el cabezal y la guía del eje X.

El sistema debe recuperar la silueta externa sin seguir ojos, pliegues ni detalles decorativos. La Figura 3 reúne varias de las condiciones observadas durante la adquisición.

2.2. Fundamentos geométricos

El registro de la impresión exige distinguir dos problemas geométricos. La calibración describe cómo la cámara forma la imagen, mientras que la homografía relaciona la hoja observada con un plano de dimensiones conocidas.



Figura 3: Dificultades visuales presentes en las capturas reales. El panel superior izquierdo muestra una iluminación desigual, con una sombra horizontal que atraviesa la hoja y el soporte. El panel superior derecho incorpora parte del cabezal dentro del campo visual. En la fila inferior se observan, respectivamente, la rotación de la hoja y su desplazamiento lateral respecto a la posición habitual. Los marcadores de las esquinas permiten rectificar la escena antes de segmentar los diseños pese a esas diferencias.

2.2.1. Calibración y distorsión de cámara

La calibración intrínseca estima la distancia focal, el punto principal y los coeficientes que describen la distorsión del objetivo. El procedimiento de Zhang sigue siendo una referencia para obtener estos parámetros a partir de varias observaciones de un patrón plano (Zhang, 2000). Trabajos posteriores muestran que la calidad de las esquinas detectadas y las diferencias entre zonas del sensor influyen en el resultado de la calibración (K. Wang, Liu, y Shen, 2022).

En este TFM no se completa una calibración intrínseca formal. La captura se concentra en la zona central del teléfono y la corrección dominante se resuelve mediante una transformación planar. Esta elección es suficiente para validar el software, pero deja abierta la posibilidad de error radial en la periferia. La limitación se declara porque la homografía corrige perspectiva, no todas las deformaciones de lente.

2.2.2. Homografía y rectificación planar

Una homografía es una transformación proyectiva entre dos planos. Permite relacionar la hoja observada en perspectiva con un rectángulo de dimensiones conocidas. En coordenadas homogéneas, un punto (x, y) de la imagen original se transforma en (x', y') mediante

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} \sim H \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}, \quad H = \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & 1 \end{bmatrix}. \quad (2.1)$$

Las cuatro correspondencias de esquina aportadas por los marcadores permiten estimar H y llevar la hoja a un lienzo de 2100×2970 píxeles. Investigaciones recientes confirman la utilidad de la homografía para corregir distorsión de perspectiva en mediciones planas (C. Wang y cols., 2025). La Figura 4 muestra el sentido de esta transformación dentro del sistema.

Los marcadores fiduciales se utilizan con frecuencia para recuperar posición y orientación a partir de patrones conocidos (Garrido-Jurado, Muñoz-Salinas, Madrid-Cuevas, y Marín-Jiménez, 2014). Aquí los cuatro cuadrados delimitan la hoja, mientras que la marca en L cumple una función diferente. Su vértice define el origen WCS y sus brazos aportan la dirección de los ejes.




Figura 4: Rectificación de la hoja mediante correspondencias entre los marcadores detectados y el plano canónico A4.

2.3. Segmentación mediante visión clásica

Los métodos clásicos separan regiones a partir de propiedades expresadas de forma explícita. En este caso resultan útiles la saturación, la luminosidad, los gradientes y la conectividad espacial. La corrección de brillo y la segmentación adaptativa se han empleado en escenas industriales con reflejos (Q. Li, Zheng, Wang, y Li, 2023), mientras que los operadores adaptativos de borde buscan conservar límites de pieza bajo ruido variable (Y. Li y cols., 2024).

El detector de Canny combina suavizado, gradiente, supresión de no máximos e histéresis (Canny, 1986). Sin embargo, una imagen de topper contiene muchas líneas internas. Por eso el borde no se usa solo. Se combina con umbrales en HSV y con operaciones morfológicas que cierran discontinuidades y rellenan la región externa. El resultado constituye una línea base interpretable y también un localizador aproximado de las cajas que recibe SAM 2.

2.4. Aprendizaje automático para segmentación

Los métodos de aprendizaje considerados representan dos niveles de complejidad. Random Forest aprende una decisión por píxel a partir de características diseñadas, mientras que SAM 2 reutiliza una representación neuronal preentrenada y recibe una guía espacial mediante prompts.

Los antecedentes industriales citados permiten concretar qué significa esa incorporación de IA. Ozkan compara regresión logística, máquinas de vectores de soporte, árboles de decisión, Random Forest, XGBoost y una red neuronal artificial después de extraer descriptores geométricos. La red neuronal obtuvo el mejor resultado en la detección de defectos de casquillos metálicos (Ozkan, 2025). Loganathan et al. emplean YOLOv8n-seg para segmentación multiclase de defectos de soldadura y medición geométrica en tiempo real (Loganathan y cols., 2026). Ambos trabajos combinan aprendizaje con procesamiento visual previo y muestran que el modelo debe describirse por su función concreta dentro de la cadena.

2.4.1. Random Forest como clasificador por píxel

Random Forest agrega las predicciones de varios árboles entrenados con muestreo y selección aleatoria de características (Breiman, 2001). La combinación reduce la varianza de un árbol individual y permite modelar relaciones no lineales sin una red neuronal profunda. En una segmentación por píxel, cada observación se describe mediante color, gradiente y textura local. El modelo estima entonces la probabilidad de que ese píxel pertenezca al topper.




Figura 5: Funcionamiento del Random Forest por píxel, desde la extracción de características hasta la agregación de los árboles y la formación de la máscara.

La Figura 5 resume el procedimiento. Su principal ventaja para este proyecto es que puede entrenarse con un volumen moderado de datos y ofrece una referencia supervisada distinta de las reglas clásicas. Su mayor riesgo es la dependencia del dominio. Un clasificador puede aprender con gran precisión el blanco digital, las sombras programadas y las texturas sintéticas, pero fallar cuando la cámara introduce ruido, compresión y variaciones cromáticas que no aparecieron en el entrenamiento.

2.4.2. Redes convolucionales y alternativas consideradas

Las redes convolucionales aprenden representaciones jerárquicas a partir de los datos (LeCun, Bottou, Bengio, y Haffner, 1998). U-Net combina un codificador con un decodificador y conexiones de salto para recuperar detalle espacial (Ronneberger, Fischer, y Brox, 2015). Mask R-CNN añade una rama de máscara a un detector regional (He, Gkioxari, Dollár, y Girshick, 2017), mientras que YOLO plantea una detección directa orientada a velocidad (Redmon, Divvala, Girshick, y Farhadi, 2016).

Estas arquitecturas son válidas, pero exigirían un conjunto real con numerosas instancias anotadas y diversidad de diseños. Las trece fotografías disponibles corresponden a una sola lámina física, de modo que entrenar una red propia desde cero produciría una evaluación poco defendible. El banco sintético ayuda a estudiar transferencia, pero no sustituye la variabilidad de producción. Por esa razón se elige un modelo preentrenado que puede trabajar con prompts y no necesita ajuste sobre las imágenes del proyecto.

2.4.3. Modelos fundacionales y SAM 2

Un modelo fundacional se preentrena con un conjunto amplio y diverso para adquirir representaciones reutilizables en tareas posteriores. En lugar de aprender desde cero cada nuevo problema, se adapta mediante prompts, ajuste fino o módulos ligeros. En segmentación, SAM introdujo un esquema capaz de producir máscaras a partir de puntos o cajas y mostró transferencia sin entrenamiento específico a distintas distribuciones visuales (Kirillov y cols., 2023).

SAM 2 extiende la segmentación condicionada a imágenes y vídeo. Su arquitectura combina un codificador visual jerárquico, un codificador de prompts y un decodificador de máscaras. La memoria temporal es relevante para vídeo, aunque en este TFM cada hoja se procesa como una imagen independiente (Ravi y cols., 2025). La variante Hiera Tiny es la opción más ligera de la familia utilizada. Se selecciona porque puede ejecutarse en CPU y porque el objetivo es integrar el modelo en una herramienta de taller, no maximizar el tamaño de la red.

La Figura 6 diferencia la imagen, el prompt y la máscara resultante. El modelo no se entrena con los datos del TFM. Se carga un checkpoint preentrenado y se comparan distintas formas de construir el prompt. Esta decisión evita presentar como aprendizaje propio lo que en realidad es transferencia desde un modelo fundacional. También obliga a




Figura 6: Arquitectura funcional de SAM 2 para una imagen estática condicionada mediante cajas geométricas.

declarar una dependencia: SAM 2 necesita una localización inicial. En las capturas reales, esa localización procede de componentes obtenidas por el módulo clásico, pero sus bordes no se reutilizan como máscara final.

2.5. Métricas de segmentación

La evaluación de una máscara exige medir algo más que el porcentaje de píxeles acertados, porque el fondo ocupa gran parte de la hoja. La intersección sobre unión, conocida como IoU o índice de Jaccard, divide el área común entre la unión de la predicción y la referencia. El coeficiente Dice duplica la intersección y la divide entre la suma de ambas áreas. Las dos medidas toman el valor uno cuando las máscaras coinciden y disminuyen con los falsos positivos y falsos negativos. Dice suele producir un valor numérico mayor que IoU para el mismo par de máscaras, aunque ambas ordenan de forma coherente el grado de solapamiento (Taha y Hanbury, 2015).

El Boundary F1 traslada la comparación al borde. Un punto predicho se considera correcto cuando cae dentro de una tolerancia alrededor del contorno de referencia. A partir de la precisión y la exhaustividad de esos puntos se calcula su media armónica, siguiendo el protocolo de correspondencia tolerante utilizado para evaluar límites en imágenes (Martin, Fowlkes, y Malik, 2004). Esta métrica resulta útil para corte porque dos máscaras pueden tener un área similar y, sin embargo, diferir en apéndices finos o entrantes de la silueta. El error de componentes complementa el análisis al comparar la cantidad de regiones conectadas con las instancias esperadas.

2.6. Vectorización y geometría fabricable

Una máscara binaria todavía no constituye una trayectoria de máquina. El contorno contiene una gran cantidad de vértices y pequeñas irregularidades propias del raster. Una polilínea es una secuencia ordenada de segmentos rectos que aproxima ese límite y que puede cerrarse para describir la silueta completa.

El algoritmo de Douglas-Peucker reduce los puntos redundantes dentro de una tolerancia geométrica ε (Douglas y Peucker, 1973). El procedimiento une primero los extremos de una secuencia y localiza el punto con mayor distancia perpendicular al segmento. Si esa distancia supera ε , divide la curva en ese punto y repite el cálculo en cada parte. Si no lo supera, conserva únicamente los extremos. Un valor pequeño mantiene más detalle y produce más vértices, mientras que uno grande simplifica la trayectoria y puede deformar rasgos finos. Por ello, la tolerancia debe expresarse en relación con la escala física de la imagen.

La literatura que conecta imagen y fabricación confirma la necesidad de validar la salida como geometría y no solo como visualización. Bhandari y Manandhar combinan visión y CAD para recuperar dimensiones (Bhandari y Manandhar, 2023). Jednoróg desarrolla una herramienta orientada a generar DXF desde fotografías en un entorno de pequeña empresa (Jednorog, 2025). Khafagy et al. estudian la extracción y optimización de trayectorias complejas desde gráficos vectoriales para aplicaciones robóticas (Khafagy y cols., 2025). En todos los casos, la utilidad final depende de conservar escala, conectividad y referencia espacial.

2.7. Síntesis crítica

La revisión conduce a una arquitectura híbrida. La geometría controlada resuelve la rectificación y el WCS de forma auditable. Un localizador clásico aporta cajas aproximadas con un coste bajo. SAM 2 refina las siluetas mediante conocimiento preentrenado y su máscara alimenta la vectorización. Random Forest permite estudiar el aprendizaje supervisado por píxel y la brecha sintético-real.

Esta combinación no presupone que la inteligencia artificial mejorará todas las métricas. La evaluación debe mostrar cuándo aporta una segmentación útil y cuándo una regla específica del entorno sigue siendo más precisa. El criterio de diseño es que la aplicación

final use el modelo de IA de forma real y trazable, sin borrar el papel de los componentes geométricos que hacen posible el registro físico.

3. Objetivos

Los objetivos delimitan tanto la construcción de la herramienta como la evaluación experimental de sus métodos de segmentación. Se separa la meta general de las tareas verificables que permiten alcanzarla.

3.1. Objetivo general

Diseñar, implementar y evaluar una herramienta software basada en inteligencia artificial que, a partir de una fotografía de una hoja adhesiva impresa, rectifique la escena, segmente los *toppers* mediante SAM 2 y genere trayectorias DXF registradas con el sistema de coordenadas del láser CNC, comparando su desempeño con Random Forest y una línea base clásica.

3.2. Objetivos específicos

- OE1.** Definir un procedimiento de captura con una cámara de consumo sobre una región delimitada de la mesa, adecuada para hojas adhesivas de formato A4.
- OE2.** Implementar la detección de marcadores, la rectificación por homografía y la localización de una marca grabada por el láser para relacionar la imagen con el sistema de coordenadas de trabajo.
- OE3.** Construir un conjunto sintético controlado y un protocolo con particiones independientes de entrenamiento, validación y prueba para evaluar métodos de segmentación.
- OE4.** Entrenar y optimizar un Random Forest por píxel mediante validación agrupada, selección de hiperparámetros y ajuste del umbral sobre láminas completas.
- OE5.** Seleccionar una estrategia de prompts para SAM 2 Hiera Tiny, evaluar su comportamiento en los dominios sintético y real e integrarlo como motor de segmentación de la aplicación.
- OE6.** Implementar la extracción, simplificación y conversión de los contornos a coordenadas físicas, con exportación DXF condicionada a la existencia de un WCS válido.

OE7. Comparar la línea base clásica, Random Forest y SAM 2 mediante Dice, IoU, coincidencia de bordes, error de componentes y tiempo, declarando con claridad las limitaciones de los datos reales y de la validación física.

3.3. Impacto esperado

El impacto esperado es concreto: disminuir las piezas repetidas por desalineación y hacer más estable la coincidencia entre lo impreso y lo cortado. En el proceso convencional, esa coincidencia depende del pulso y la experiencia del operario. El flujo propuesto la traslada a un registro geométrico verificable. La hoja se lamina primero sobre el soporte y el corte se calcula después a partir de la captura realizada sobre el material real.

La calidad geométrica ocupa el primer lugar. El tiempo de preparación es relevante, pero no constituye el criterio principal de esta fase. Una solución rápida que produzca contornos desplazados no aporta valor al taller. Por ello se evalúan la coincidencia de la máscara, la estabilidad del registro y la capacidad de generar una trayectoria utilizable.

El uso de una cámara de consumo, una hoja con marcadores sencillos y un modelo neuronal que puede ejecutarse en CPU mantiene el prototipo dentro de una escala razonable para Innokey. Además, el resultado experimental aporta conocimiento más allá del caso de uso. Permite observar con datos cómo un clasificador puede rendir de forma sobresaliente en sintético y fallar en real, y cómo un modelo fundacional condicionado por prompts conserva mejor su desempeño sin necesidad de entrenamiento local.

4. Identificación de requisitos

Los requisitos se derivan del proceso observado en Innokey, de los objetivos del TFM y de la necesidad de mantener la inteligencia artificial dentro del flujo operativo. Cada requisito incluye un criterio verificable para evitar descripciones demasiado abiertas.

4.1. Requisitos funcionales

RF1. Carga de la captura. La herramienta debe admitir una fotografía estática de la zona de trabajo tomada con una cámara de consumo. Se verifica cuando la aplicación abre la imagen, corrige su orientación y la muestra al usuario.

RF2. Detección de la hoja. El sistema debe localizar los cuatro marcadores de esquina y ordenar sus posiciones. Se verifica cuando identifica las cuatro referencias válidas o informa de forma explícita que la rectificación no puede continuar.

RF3. Rectificación geométrica. La captura debe transformarse a un plano A4 mediante la homografía calculada con los marcadores. El lienzo resultante debe medir 2100×2970 píxeles, a una escala de 10 px/mm.

RF4. Detección del WCS. La aplicación debe localizar la marca en L grabada por el láser y recuperar su origen y direcciones de eje. Cuando la marca no exista o sea insuficiente, el sistema debe continuar en modo de análisis y bloquear la exportación en coordenadas físicas.

RF5. Localización aproximada de instancias. El módulo clásico debe proponer cajas para los toppers mediante componentes conectadas y filtros de área. Estas cajas se utilizan como prompts y no como contorno final.

RF6. Segmentación mediante IA. SAM 2 debe producir la máscara binaria final de las instancias localizadas. Si el checkpoint, las dependencias o los prompts no están disponibles, la aplicación debe mostrar un error y no sustituir silenciosamente la salida por la máscara clásica.

RF7. Vectorización. Los contornos obtenidos de la máscara de SAM 2 deben simplificarse y transformarse a unidades físicas, conservando una trayectoria exterior por topper y los huecos relevantes cuando existan (Douglas y Peucker, 1973).

- RF8. Exportación DXF.** El sistema debe generar un archivo DXF compatible con el flujo CAD/CAM cuando exista WCS válido. Las trayectorias de corte y la referencia auxiliar deben almacenarse en capas diferenciadas.
- RF9. Revisión visual.** La interfaz debe mostrar la imagen original, la hoja rectificadas, los prompts, la máscara de IA y la previsualización de los vectores para que el operario pueda detectar un resultado anómalo antes de exportarlo.
- RF10. Informe de ejecución.** Cada procesamiento debe registrar el método de segmentación, la fuente de los prompts, el estado del WCS, el número de contornos y el tiempo de ejecución.

4.2. Requisitos no funcionales

- RNF1. Bajo coste de captura.** La solución debe funcionar con un teléfono inteligente y un soporte removible, sin exigir una cámara industrial fija.
- RNF2. Reproducibilidad.** Las particiones de datos, configuraciones, versiones de dependencias y checksums de los modelos deben quedar documentados.
- RNF3. Trazabilidad algorítmica.** La máscara que recibe el extractor de contornos debe ser exactamente la generada por SAM 2. Esta relación debe poder verificarse mediante pruebas automatizadas.
- RNF4. Robustez controlada.** El sistema debe conservar las ocho instancias en las capturas reales evaluadas bajo sombras, recolocación de cámara y cambios de posición del material. Las condiciones que excedan este alcance deben declararse como limitaciones.
- RNF5. Interoperabilidad.** La salida debe incorporarse al flujo CAD/CAM existente sin obligar a reemplazar el software de preparación del corte.
- RNF6. Usabilidad.** El operario debe poder ejecutar el flujo principal desde una sola ventana y recibir mensajes claros cuando falte el WCS o no pueda cargarse el modelo.
- RNF7. Ejecución local.** La segmentación debe poder realizarse en CPU y sin enviar imágenes del taller a servicios externos.

RNF8. Mantenibilidad. La detección geométrica, la segmentación, la extracción de contornos y la exportación deben permanecer en módulos separados, de modo que un componente pueda sustituirse sin reescribir el resto del flujo.

4.3. Criterios de aceptación del prototipo

El prototipo se considera aceptado dentro del alcance computacional cuando cumple cuatro condiciones. Primero, procesa una captura real con cuatro marcadores y recupera la hoja rectificadas. Segundo, localiza ocho cajas y obtiene ocho componentes mediante SAM 2. Tercero, la misma máscara neuronal llega al extractor de contornos. Cuarto, una imagen con marca WCS válida produce un DXF no vacío con ocho trayectorias principales.

Estos criterios no sustituyen la prueba física de corte. Verifican que el software conecta sus módulos de principio a fin y que la inteligencia artificial no queda limitada a una comparación aislada fuera de la aplicación.

5. Metodología

La metodología se diseñó para responder dos preguntas relacionadas. La primera es si los métodos de inteligencia artificial pueden segmentar los toppers con suficiente fidelidad geométrica para alimentar la vectorización. La segunda es cómo cambia su comportamiento cuando se pasa de hojas sintéticas controladas a fotografías reales del taller. La evaluación separa la selección de configuraciones de la prueba final y utiliza la lámina completa como unidad experimental.

5.1. Diseño general del estudio

El trabajo combina desarrollo software y experimentación cuantitativa. La parte de desarrollo implementa un flujo de captura, registro, segmentación, vectorización y exportación. La parte experimental compara tres métodos de segmentación:

- una línea base clásica basada en color, bordes y morfología.
- un Random Forest supervisado por píxel.
- SAM 2 Hiera Tiny condicionado mediante cajas.

La Figura 7 resume el protocolo. Las 48 hojas sintéticas se dividen antes de cualquier ajuste. Las 36 de entrenamiento se usan para construir Random Forest. Las 6 de validación permiten seleccionar umbrales, candidatos y estrategias de prompt. Las 6 de prueba permanecen bloqueadas hasta cerrar esas decisiones. Las 13 capturas reales se utilizan como evaluación externa de transferencia y no intervienen en la selección del modelo principal.

5.2. Montaje y adquisición de imágenes reales

El montaje se realizó en la cortadora láser CO₂ de Innokey. Una hoja A4 con ocho toppers se adhirió sobre una plancha de MDF. La hoja incluía cuatro marcadores cuadrados, una escala impresa de 50 mm y una zona libre para la marca WCS. La cámara del teléfono se fijó a la compuerta superior mediante un soporte removible.

La Figura 8 permite distinguir la hoja adherida, la zona de trabajo y la posición elevada desde la que se toma la fotografía. El soporte removible mantiene el teléfono fuera del recorrido del cabezal, aunque no garantiza una pose idéntica entre sesiones.




Figura 7: Diseño experimental con separación por lámina y bloqueo del conjunto de prueba hasta cerrar las decisiones de modelo y prompt.



Figura 8: Montaje utilizado para capturar la hoja A4 adherida al MDF dentro de la cortadora láser.

Se seleccionaron trece fotografías: 13, 15, 17, 20, 22, 24, 26, 28, 30, 32, 34, 36 y 38. Las tres primeras no contienen una marca WCS utilizable. Las diez restantes incluyen la marca en L y cubren cambios de sombra, recolocación del teléfono, rotación y desplazamiento del MDF. Todas corresponden a la misma hoja física con una estrella, un arcoíris, una mariposa, un dinosaurio, una princesa, un unicornio, un camión y una sirena.

Esta última precisión afecta la interpretación estadística. Existen trece capturas, pero no trece diseños independientes. Las variaciones observadas describen robustez frente a la adquisición de una hoja concreta. No permiten estimar por sí solas la generalización a nuevos productos.

La Figura 9 presenta seis capturas representativas en lugar de reducir las trece fotografías a miniaturas. La selección conserva cambios de sombra, presencia del cabezal, recolocación del teléfono y desplazamiento del MDF. Las siete capturas restantes forman parte de la evaluación cuantitativa y permanecen disponibles en el repositorio.

5.3. Construcción del conjunto sintético

El conjunto sintético parte de 32 toppers con canal alfa, organizados en cuatro grupos visuales. Estos elementos se combinaron en 48 hojas A4 mediante cuatro familias, dos distribuciones y seis condiciones de captura simulada. Las condiciones incluyen iluminación uniforme, sombras superiores e inferiores, contraste reducido, ruido con desenfoque y una deformación suave.

Cada hoja se acompaña de una máscara binaria, metadatos y cajas de instancia. La máscara procede del canal alfa durante la composición y constituye una referencia conocida. La partición se realiza por identificador de hoja, no por píxel. De este modo ningún píxel de una lámina aparece en más de un subconjunto.

La Figura 10 muestra ocho hojas que cubren las cuatro familias y varias condiciones de captura simulada. Se evita presentar las 48 láminas a un tamaño que impida reconocer los diseños. El manifiesto conserva la relación completa de archivos y particiones.

La Tabla 1 resume la separación aplicada antes de entrenar o seleccionar cualquier configuración. La unidad de partición es la lámina completa, por lo que una misma hoja no aporta píxeles a más de un subconjunto.

Las hojas sintéticas comparten el banco de 32 gráficos. Por ello, la prueba sintética mide cambios de composición y condición, pero no una separación completa de identidades vi-

Muestras representativas del conjunto real



Se muestran 6 de las 13 capturas; todas corresponden a una misma hoja física rectificada.

Figura 9: Seis capturas rectificadas representativas del conjunto real. La fila superior muestra la captura 13 sin WCS, la captura 17 con sombra inferior y la captura 20 con la marca WCS visible. La fila inferior presenta la captura 24 con sombra y cabezal, la captura 30 después de recolocar el teléfono y la captura 38 con el MDF desplazado. Todas contienen los mismos ocho diseños porque proceden de una sola hoja física. La selección visual no altera la evaluación, que utiliza las trece fotografías.

Ejemplos de familias y condiciones sintéticas



Se muestran 8 de las 48 hojas; F identifica la familia, L la distribución y C la condición visual.

Figura 10: Ocho ejemplos del conjunto de hojas sintéticas. Cada columna corresponde a una familia visual y cada fila utiliza una distribución diferente. Entre las muestras aparecen iluminación uniforme, sombras, contraste reducido y ruido con desenfoque. Los identificadores impresos sobre cada panel permiten localizar la imagen, la máscara y sus metadatos en el repositorio. Las 48 hojas, y no solo las ocho representadas, se utilizan en las particiones experimentales.

Tabla 1: Particiones utilizadas en el protocolo experimental.

Conjunto	Láminas	Instancias	Uso
Sintético de entrena- miento	36	288	Ajuste de Random Forest y valida- ción cruzada agrupada
Sintético de valida- ción	6	48	Selección de modelo, umbral y prompts
Sintético de prueba	6	48	Evaluación final, una vez bloquea- das las decisiones
Real externo	13 capturas	104 observacio- nes de 8 diseños	Transferencia de dominio sobre una misma hoja física

suales. El dominio real sí introduce ocho diseños distintos, además del papel, la iluminación y el ruido de cámara.

5.4. Referencia canónica del dominio real

Las trece fotografías se rectifican al mismo plano A4. Como muestran la misma hoja física, se construyó una referencia canónica común en esas coordenadas. Primero se calculó la mediana por píxel de las trece capturas, lo que reduce sombras y elementos transitorios. Después se inicializó GrabCut con una caja por topper, se incorporaron bordes Canny para cerrar zonas claras y se rellenaron los contornos externos.

Las salidas clásicas y las de SAM 2 no se utilizaron como etiquetas de píxel. Las cajas proceden de una localización clásica aproximada y sirven solo para delimitar cada región durante la construcción asistida. La máscara final se inspeccionó sobre la imagen mediana. El control verificó ocho regiones separadas, exclusión de marcadores y de la marca WCS, conservación de apéndices finos y mantenimiento del hueco interno del arcoíris.

Esta referencia evita medir los métodos únicamente por su acuerdo con la máscara clásica. Pese a ello, no se presenta como una anotación manual independiente de varias hojas. Es una referencia asistida para un plano canónico y su naturaleza forma parte de las limitaciones del estudio.

5.5. Línea base de visión clásica

La línea base combina tres fuentes de información. La saturación $S > 45$ captura colores y tonos pastel. El valor $V < 115$ incorpora trazos oscuros. Los bordes obtenidos mediante Canny ayudan a cerrar regiones claras. Antes de unir estas señales se excluyen los márgenes, los marcadores y, cuando está disponible, la marca WCS.

La máscara combinada recibe cierre morfológico, rellenado desde el fondo y apertura. Finalmente se eliminan componentes pequeñas. Este método no tiene fase de entrenamiento ni selección sobre validación. Se conserva con sus parámetros previos como línea base fija y como generador de cajas aproximadas para la aplicación.

Los valores se congelaron antes de evaluar los conjuntos finales y no forman parte de la búsqueda de hiperparámetros. El umbral $S > 45$ separa la mayor parte de los colores impresos del fondo blanco, mientras que $V < 115$ recupera trazos oscuros que pueden tener poca saturación. El elemento morfológico de 7×7 píxeles equivale a 0,7 mm a la escala de trabajo y cierra discontinuidades locales sin unir objetos separados. El área mínima de 20 000 píxeles, equivalente a 200 mm^2 , descarta marcadores y residuos menores que los *toppers* del montaje. Estos criterios proceden del diseño previo de la línea base y se mantienen fijos para no ajustarla a los resultados de prueba.

5.6. Random Forest y optimización de hiperparámetros

La construcción de Random Forest comprende la representación de cada píxel, el muestreo del conjunto de entrenamiento y una búsqueda de configuraciones que respeta la separación entre láminas. La decisión final no se apoya únicamente en la validación interna, sino también en la reconstrucción de hojas completas.

5.6.1. Características y muestreo

Cada píxel se representa mediante 19 características. Nueve corresponden a tres espacios de color. RGB conserva las intensidades roja, verde y azul de la captura. HSV separa matiz, saturación y valor, lo que ayuda a distinguir el papel blanco de los diseños cromáticos y de los trazos oscuros. Lab representa luminosidad y dos ejes cromáticos aproximadamente oponentes, por lo que aporta una descripción menos ligada al dispositivo. Cuatro características describen gradiente y borde mediante Sobel horizontal, Sobel vertical, magnitud

y Laplaciana. Las seis restantes recogen suavizados gaussianos y diferencias entre escalas para representar cambios locales de textura. Las coordenadas absolutas se excluyen para evitar que el modelo memorice posiciones de la plantilla.

Para la búsqueda se toman 2000 píxeles de objeto y 2000 de fondo por cada una de las 36 láminas de entrenamiento. La mitad de los negativos procede del fondo cercano al borde y la otra mitad del fondo lejano. El conjunto de ajuste contiene así 144 000 observaciones. Se aplican variaciones de exposición, balance de blancos, ruido y color del fondo.

5.6.2. Búsqueda agrupada

Se utiliza `RandomizedSearchCV` con diez candidatos y cuatro particiones `GroupKFold`. El grupo es la lámina completa, por lo que los píxeles de una hoja nunca se reparten entre entrenamiento y validación interna. La función principal de puntuación es Jaccard, equivalente a IoU para la clase positiva.

El espacio de búsqueda incluye:

- entre 100 y 300 árboles.
- profundidad máxima de 12, 18, 25 o sin límite.
- mínimo de 1, 2, 4 u 8 muestras por hoja del árbol.
- mínimo de 2, 5 o 10 muestras por división.
- selección de características igual a raíz cuadrada, 50 % u 80 %.
- balanceo global o por submuestra.

La puntuación sobre píxeles muestreados no basta para decidir qué modelo sirve para vectorizar una hoja. Por ello se realiza una segunda etapa sobre las seis láminas completas de validación. Se comparan el ganador de la búsqueda, un control entrenado con aumentación y otro control sin aumentación. Para cada candidato se examinan umbrales entre 0,30 y 0,75.

La regla de selección es

$$S = \overline{\text{IoU}} - 0,005 \overline{E_c}, \quad (5.1)$$

donde E_c es el error absoluto en el número de componentes. Esta penalización evita favorecer una máscara con buen solapamiento global pero fragmentada en regiones espurias. El candidato y el umbral ganadores se bloquean antes de abrir el conjunto de prueba.

5.7. SAM 2 y selección de prompts

SAM 2 se utiliza con el checkpoint Hiera Tiny preentrenado, sin ajuste fino sobre los datos del proyecto. La elección responde al tamaño reducido del conjunto real y a la necesidad de ejecutar el prototipo en CPU. Entrenar una red desde cero con trece vistas de una sola hoja no aportaría una base suficiente para evaluar generalización.

En las seis hojas sintéticas de validación se comparan cinco estrategias:

- caja ajustada.
- caja con 5 % de margen.
- caja con 10 % de margen.
- caja y un punto positivo central.
- caja, punto positivo y cuatro puntos negativos.

SAM 2 genera tres candidatos por prompt. Se ordenan por la confianza predicha y se descartan, cuando es posible, los que presentan un área incompatible con la caja. Las máscaras elegidas se acumulan, se someten a un cierre 3×3 y se eliminan componentes menores de 300 píxeles. La estrategia con mayor puntuación de selección se aplica una sola vez a las seis hojas de prueba.

En sintético, las cajas proceden de los metadatos del generador. En real, el localizador clásico obtiene ocho componentes aproximadas y las convierte en cajas. El margen se aplica sobre esas cajas y SAM 2 define los bordes finales. Este diseño separa la localización de la segmentación, pero también significa que SAM 2 no actúa como detector autónomo.

5.8. Métricas y análisis

Las métricas se calculan por lámina. Dada una referencia G y una predicción P , la intersección sobre unión se define como

$$\text{IoU}(G, P) = \frac{|G \cap P|}{|G \cup P|}, \quad (5.2)$$

y el coeficiente Dice como

$$\text{Dice}(G, P) = \frac{2|G \cap P|}{|G| + |P|}. \quad (5.3)$$

IoU penaliza de forma directa los falsos positivos y falsos negativos. Dice expresa el mismo solapamiento en una escala algo más favorable y facilita la comparación con trabajos de segmentación. Boundary F1 evalúa la coincidencia de los bordes dentro de una tolerancia de tres píxeles. El error de componentes mide la diferencia entre el número de regiones válidas predichas y esperadas. El tiempo incluye la inferencia y el postprocesamiento específico de cada método cuando se ejecuta de nuevo.

En prueba sintética se presentan media y desviación estándar sobre seis láminas. En real se añade un intervalo percentil bootstrap de 10 000 remuestreos sobre las trece capturas. Ese intervalo describe variación de adquisición de una misma hoja y no debe interpretarse como generalización a nuevos diseños.

5.9. Trazabilidad y reproducibilidad

Un manifiesto canónico registra identificador, dominio, partición, ruta, dimensiones y SHA-256 de cada muestra. Los checkpoints y modelos incluyen checksum, y los resultados se guardan en CSV o JSON. Las tablas de evaluación se construyen a partir de esos archivos. El código, las configuraciones y las fuentes de la memoria se mantienen bajo control de versiones.

Las pruebas automatizadas verifican que la máscara entregada por el adaptador de SAM 2 sea la misma que recibe el extractor de contornos, que la ausencia del checkpoint produzca un error y que no exista un retorno silencioso al método clásico. Además, una ejecución real completa comprueba la cadena desde la imagen hasta el DXF.

6. Descripción de la herramienta software desarrollada

La contribución operativa del TFM es una aplicación modular que transforma una fotografía del material en trayectorias vectoriales. La herramienta no presenta SAM 2 como un experimento separado. El modelo forma parte de la ruta que utiliza la interfaz y su máscara es la entrada real de la extracción de contornos.

6.1. Arquitectura general

La arquitectura separa las tareas geométricas, la localización aproximada y la segmentación neuronal. La visión clásica detecta los marcadores, calcula la homografía, busca la marca WCS y propone cajas. SAM 2 recibe la hoja rectificada y esas cajas. La máscara resultante pasa al módulo de contornos, se transforma a milímetros y se exporta cuando existe una referencia WCS válida.




Figura 11: Arquitectura híbrida implementada. La localización clásica aporta cajas y SAM 2 genera la máscara que alimenta la vectorización.

La Figura 11 destaca una decisión importante. La máscara clásica puede visualizarse como línea base y utilizarse para obtener componentes, pero no sustituye la salida de SAM 2 dentro de la aplicación. Si el checkpoint no está disponible o el modelo no puede inicializarse, el flujo se detiene con un mensaje de error.

6.2. Organización del código

El software se implementó en Python y conserva un módulo por responsabilidad. Esta separación facilita las pruebas y permite sustituir el segmentador sin alterar el registro geométrico o la exportación.

Tabla 2: Módulos principales de la herramienta.

Módulo	Responsabilidad
<code>load_images.py</code>	Carga de la captura, lectura de orientación EXIF y rotación cuando es necesaria.
<code>detect_markers.py</code>	Localización y ordenamiento de los cuatro marcadores de la hoja.
<code>rectify_sheet.py</code>	Estimación de la homografía y generación del plano A4 canónico.
<code>detect_wcs_l.py</code>	Detección del vértice y de las direcciones de la marca WCS.
<code>segmenters/prompts.py</code>	Conversión de componentes aproximadas en cajas y aplicación del margen seleccionado.
<code>segmenters/sam2 _segmenter.py</code>	Carga diferida del checkpoint, ejecución de SAM 2 y postprocesamiento de la máscara.
<code>ai_pipeline.py</code>	Conexión explícita entre localización, segmentación neuronal y contornos.
<code>extract_contours.py</code>	Extracción de siluetas y simplificación geométrica.
<code>export_dxf.py</code>	Conversión a milímetros y escritura de capas DXF.
<code>gui.py</code>	Interfaz de usuario, visualización de etapas y control de exportación.

La Tabla 2 relaciona cada responsabilidad con el archivo que la implementa. La segmentación neuronal queda aislada detrás de un adaptador, mientras que la orquestación de la ruta operativa corresponde a `ai_pipeline.py`.

La configuración se concentra en un archivo YAML. Allí se declaran el segmentador predeterminado, la ruta del checkpoint, la variante del modelo, el dispositivo, el margen de caja, la escala de trabajo y los parámetros de contorno. La interfaz de línea de comandos utiliza SAM 2 de forma predeterminada. La visión clásica solo puede seleccionarse de manera explícita para reproducir la línea base.

6.3. Carga, marcadores y rectificación

Las fotografías del teléfono pueden almacenarse con una orientación distinta de la que muestra el visor. El cargador interpreta la información EXIF, siglas de *Exchangeable Image File Format*, donde el dispositivo registra metadatos como la orientación de la captura. También permite una rotación adicional cuando esa información no está disponible o no coincide con la posición del montaje. Después, el detector busca componentes cuadradas oscuras cerca de las esquinas, filtra candidatos y ordena los cuatro puntos.

La homografía lleva esos puntos a las esquinas del lienzo canónico. Todas las etapas posteriores trabajan sobre 2100×2970 píxeles. La escala de 10 px/mm simplifica la conversión a unidades físicas y hace comparables las trece capturas.

6.4. Detección del sistema de coordenadas de trabajo

La marca en L se busca en una región reservada de la hoja. El algoritmo separa trazos oscuros, ajusta una recta a cada brazo y calcula su intersección. El vértice define el origen. Los vectores unitarios de los brazos determinan la orientación local.

La exportación está protegida por una regla de seguridad. Si el estado del WCS no es válido, la herramienta permite revisar la hoja, los prompts, la máscara y los contornos, pero no genera coordenadas de corte. Esta decisión evita que un resultado visualmente correcto se importe con un origen falso.

6.5. Localización y segmentación con SAM 2

El localizador clásico produce una máscara aproximada mediante HSV, trazos oscuros y bordes. A continuación se calculan componentes conectadas dentro de un rango de área. Si aparecen más de ocho candidatas, se conservan las de mayor tamaño. Las cajas se ordenan de arriba abajo y de izquierda a derecha para mantener una presentación estable.

Cada caja recibe un margen del 5 %, valor seleccionado en validación. El adaptador carga SAM 2 solo en el primer uso, convierte la imagen BGR a RGB y solicita tres máscaras por prompt. La selección considera la confianza del modelo y la compatibilidad entre el área de la máscara y la caja. Las ocho predicciones se combinan en una máscara binaria, se cierran discontinuidades pequeñas y se eliminan regiones menores de 300 píxeles.

El resultado incluye metadatos sobre la familia, la variante, el dispositivo, el margen y las puntuaciones. La aplicación muestra también que la fuente de los prompts es el localizador clásico. Esta información evita que la arquitectura híbrida se confunda con una detección neuronal completamente autónoma.

6.6. Contornos y exportación DXF

El extractor recibe la máscara de SAM 2 como objeto de entrada. A partir de ella obtiene contornos, descarta regiones incompatibles y aplica Douglas-Peucker con una tolerancia nominal de 1,5 píxeles, equivalente a 0,15 mm. Esta tolerancia es la desviación máxima admitida entre el contorno rasterizado y su aproximación. Se mantiene por debajo de dos décimas de milímetro para retirar irregularidades de píxel sin borrar detalles relevantes a la escala del corte. Las coordenadas de hoja se transforman al WCS y se escriben como polilíneas cerradas, es decir, secuencias de segmentos cuyo último vértice vuelve al primero.

El DXF separa las trayectorias principales en la capa `TOPPERS_CUT` y la referencia auxiliar en `WCS_REF`. El offset de corte se mantiene en 0,0 mm durante la validación. La compensación del ancho de corte queda disponible como parámetro, pero requiere una prueba física para ajustarse.

La Figura 12 permite seguir una ejecución real de izquierda a derecha y de arriba abajo. Resulta importante comparar la localización aproximada con la máscara neuronal: la primera solo construye las cajas, mientras que la segunda es la que llega al extractor de contornos.

Flujo operativo de IA en la captura real 20



Figura 12: Ejecución completa de la captura 20 con SAM 2. La primera fila contiene la hoja rectificada, las ocho cajas utilizadas como prompts y la máscara aproximada del localizador clásico. La segunda fila muestra la máscara final de SAM 2, los contornos extraídos a partir de ella y el registro respecto al WCS. La comparación entre ambas máscaras deja visible que la salida clásica actúa como guía espacial y no como segmentación final. El último panel confirma que las trayectorias conservan la referencia física necesaria para exportar el DXF.

6.7. Interfaz gráfica

La interfaz se desarrolló con `tkinter` y utiliza `matplotlib` para las previsualizaciones. Una zona lateral agrupa la ruta del checkpoint, la escala, el offset y el estado del procesamiento. La zona principal contiene pestañas para la captura original, la hoja rectificada, la segmentación de IA y la geometría vectorial.

El botón principal ejecuta el flujo en orden. Al terminar, la ventana informa el método utilizado, la fuente de los prompts, el número de toppers y la disponibilidad del WCS. La exportación se habilita solo cuando el registro geométrico está completo.




Figura 13: Interfaz gráfica con SAM 2 como segmentador operativo y revisión de la salida vectorial.

La Figura 13 muestra el estado posterior a una ejecución completa. La pestaña de segmentación identifica a SAM 2 como método activo y la previsualización permite revisar la salida antes de habilitar la exportación.

6.8. Verificación de la integración

La integración se comprobó mediante pruebas unitarias y una ejecución real. Las pruebas verifican cuatro comportamientos: la máscara de SAM 2 llega sin sustitución al extrac-

tor, un checkpoint ausente genera un error, el adaptador devuelve una máscara binaria y el localizador conserva las componentes esperadas.

En la captura 20, la herramienta detectó un WCS válido, generó ocho cajas, obtuvo ocho componentes con SAM 2 y extrajo ocho contornos. El resultado se exportó a un DXF de aproximadamente 65,4 kB. Esta prueba confirma la ruta operativa completa y no solo la calidad aislada de la segmentación.

7. Evaluación

Este capítulo presenta los resultados una vez cerradas las decisiones de modelo, umbral y prompt. La comparación se organiza en dos dominios. El primero corresponde a las seis hojas sintéticas de prueba, que conservan las condiciones controladas del generador. El segundo está formado por trece fotografías de una misma hoja física, rectificadas a un plano común. Esta separación permite observar no solo qué método segmenta mejor, sino también cuánto de ese rendimiento se conserva cuando cambia la imagen de entrada.

7.1. Optimización y selección de Random Forest

La búsqueda aleatoria evaluó diez configuraciones mediante cuatro particiones agrupadas, lo que produjo cuarenta ajustes con `GroupKFold`. El mejor candidato en esa etapa obtuvo un Jaccard medio de $0,8077 \pm 0,0472$ sobre los píxeles muestreados. Utilizó 300 árboles, profundidad máxima 12, ocho muestras mínimas por hoja del árbol, dos por división, 50 % de las características y balanceo de clases.

El resultado de la búsqueda no se aceptó de forma automática. Al reconstruir las seis hojas completas de validación, ese candidato alcanzó un IoU de 0,5953 y un error medio de 2,33 componentes. La diferencia frente a su puntuación interna mostró que clasificar bien una muestra balanceada de píxeles no equivale a conservar objetos completos y cerrados. Por esa razón se mantuvo la segunda etapa prevista en el protocolo y se comparó el ganador de la búsqueda con los dos controles existentes.

Tabla 3: Selección de Random Forest sobre las seis hojas completas de validación.

Candidato	Umbral	IoU val.	Error comp.	Puntuación S
Control sin aumentación	0.70	0.9903	0.00	0.9903
Control con aumentación	0.65	0.9127	0.17	0.9119
Ganador de búsqueda agrupada	0.60	0.5953	2.33	0.5836

La Tabla 3 muestra por qué se mantuvo la validación sobre hojas completas. El candidato con mejor puntuación interna no conservó la estructura de las láminas y quedó por debajo de los dos controles al reconstruir las máscaras completas.

El control sin aumentación y con umbral 0.70 fue, por tanto, la configuración bloqueada para prueba. Este modelo conserva 200 árboles, profundidad máxima 25, dos muestras

mínimas por hoja y selección de características por raíz cuadrada. Que este control supere al candidato optimizado no invalida la búsqueda. Al contrario, aporta una observación metodológica: la función de puntuación y la unidad de validación deben parecerse al uso final. En este problema, la hoja completa es más informativa que una colección balanceada de píxeles.

7.2. Selección de prompts para SAM 2

Las cinco estrategias se compararon únicamente sobre validación. La caja con un margen del 5 % obtuvo el mayor IoU, 0,9082, seguida de la caja ajustada con 0,9074. El margen del 10 % redujo ligeramente el resultado. Incorporar puntos no produjo una mejora y la estrategia con un punto positivo fue la de menor IoU, con 0,8966.

La Figura 14 ordena las cinco estrategias según su IoU medio. El eje está acotado para hacer visibles diferencias inferiores a una centésima y no debe interpretarse como una escala iniciada en cero.




Figura 14: IoU medio de las cinco estrategias de prompt de SAM 2 sobre el conjunto sintético de validación.

La diferencia entre las dos primeras opciones es pequeña, de 0,0008 puntos de IoU. El margen del 5 % se conservó porque evitaba recortar bordes próximos a la caja sin introducir demasiado fondo. Con esa decisión bloqueada, SAM 2 alcanzó en prueba un IoU de $0,9153 \pm 0,0379$, Dice de 0,9554 y Boundary F1 de 0,7234. Las seis hojas mantuvieron el número esperado de componentes.

7.3. Resultados en el dominio sintético

La Tabla 4 reúne los resultados finales. Random Forest fue el método con mayor solapamiento y mejor coincidencia de borde. SAM 2 ocupó el segundo lugar en IoU y Dice. La línea clásica obtuvo un Boundary F1 superior al de SAM 2, aunque con menor solapamiento de área. Los tres métodos conservaron la cantidad correcta de objetos.

Tabla 4: Resultados sobre las seis hojas sintéticas de prueba.

Método	IoU	Dice	Boundary F1	Error comp.	Tiempo (s)
Visión clásica	0,9016 $\pm$ 0,0439	0.9478	0.7728	0.00	0.102
Random Fo- rest sin au- mentación	0,9902 $\pm$ 0,0102	0.9951	0.9425	0.00	7.345
SAM 2 Hiera Tiny	0,9153 $\pm$ 0,0379	0.9554	0.7234	0.00	0.528

La Figura 15 facilita la comparación conjunta de las tres métricas. Las etiquetas numéricas permiten consultar el valor exacto, mientras que las tramas mantienen la distinción entre métodos si la memoria se imprime en escala de grises.




Figura 15: Comparación de IoU, Dice y Boundary F1 en las seis hojas sintéticas de prueba.

El 0,9902 de Random Forest confirma que las características de color, gradiente y escala

describen muy bien el generador sintético. También debe leerse con cautela. Las hojas de prueba cambian la distribución y la condición visual, pero comparten el banco de 32 diseños con entrenamiento. No son una prueba de identidades completamente nuevas.

El tiempo de Random Forest incluye el cálculo de las 19 características para todos los píxeles y la predicción de probabilidad en CPU. SAM 2 también se ejecutó en CPU. Las cifras sirven para dimensionar el prototipo, aunque no representan una comparación optimizada de producción.

7.4. Transferencia a capturas reales

La evaluación real utilizó la referencia canónica descrita en el Capítulo 5. La línea clásica alcanzó el mayor IoU, con 0,9787. SAM 2 quedó cerca, con 0,9536, y conservó las ocho instancias en las trece capturas. Random Forest descendió a 0,2877 y presentó un error medio de siete componentes.

Tabla 5: Resultados sobre trece capturas rectificadas de una misma hoja real.

Método	IoU	Dice	Boundary F1	Error comp.
Visión clásica	0,9787 $\pm$ 0,0159	0.9892	0.9069	0.00
Random Forest sin aumento	0,2877 $\pm$ 0,0044	0.4468	0.3030	7.00
SAM 2 Hiera Tiny	0,9536 $\pm$ 0,0083	0.9762	0.7198	0.00

La Tabla 5 concentra las métricas de las trece capturas. El intervalo de IoU representa la variación de adquisición de esa hoja concreta y no la variación entre productos independientes.

Los intervalos de IoU obtenidos mediante bootstrap fueron [0,9696, 0,9863] para visión clásica, [0,2862, 0,2902] para Random Forest y [0,9490, 0,9577] para SAM 2. Se explican en el texto para mantener la tabla legible. Como las trece imágenes muestran la misma hoja, describen variación frente a cambios de adquisición y no generalización a trece productos independientes. Esta diferencia es relevante para no atribuir al experimento un alcance que los datos no tienen.

La Figura 16 debe leerse atendiendo a tres aspectos: la conservación de las ocho siluetas, los huecos internos que no deben rellenarse y la coincidencia del borde exterior. Random Forest pierde casi toda la región de los objetos, mientras que la línea clásica y SAM 2

mantienen las instancias. En la superposición, la proximidad de los contornos azul y oliva permite localizar sus pequeñas diferencias sin depender únicamente de las métricas.

La Figura 17 resume el cambio entre dominios. La caída de Random Forest domina la comparación, mientras que SAM 2 conserva una diferencia pequeña y la línea clásica mejora bajo las condiciones controladas de la hoja real.

Random Forest perdió 0,7025 puntos de IoU entre dominios. El fondo blanco digital, las condiciones simuladas y los gráficos del generador no reprodujeron por completo la textura del papel, el balance de blancos de la cámara ni los ocho diseños reales. El control con aumentación mejoró algunos escenarios, pero la selección rigurosa sobre validación completa favoreció el control sin aumentación. El resultado final documenta, por tanto, el comportamiento del candidato elegido sin utilizar las capturas reales para corregirlo a posteriori.

SAM 2 perdió solo 0,0381 puntos y mantuvo la topología de ocho objetos. Su preentrenamiento aporta una representación visual más amplia que la aprendida por Random Forest dentro del proyecto. Sin embargo, el modelo recibe cajas generadas por el localizador clásico. El resultado demuestra segmentación neuronal condicionada y no detección autónoma.


La visión clásica fue la mejor opción en este montaje controlado. Las hojas tienen fondo claro, marcadores conocidos y una cantidad fija de toppers. Estas condiciones favorecen reglas de color y morfología cuidadosamente ajustadas. Que SAM 2 no la supere no elimina su aporte. El modelo conserva un IoU alto, muestra menor dependencia del entrenamiento local que Random Forest y permite que la herramienta final utilice IA de manera efectiva y verificable.

7.5. Repetibilidad del registro geométrico

La estabilidad del registro se calculó sobre las diez capturas con marca WCS válida. Se compararon los centroides físicos de los ocho toppers después de la rectificación y la transformación al sistema de trabajo. Esta medición evalúa la cadena geométrica, no la precisión de un corte físico.

La Tabla 6 desglosa la dispersión por diseño. Se omiten las coordenadas medias porque describen la posición de cada dibujo y no la calidad del registro. La sirena, situada en la zona más alejada del origen, concentra la mayor deriva y ayuda a interpretar el efecto del

Comparación cualitativa en la captura real 13



Superposición: clásico azul, Random Forest naranja y SAM 2 oliva

Figura 16: Comparación visual de la referencia y las predicciones sobre la captura real 13. La fila superior presenta la imagen rectificada, la referencia canónica y la máscara de visión clásica. La fila inferior muestra las salidas de Random Forest y SAM 2, junto con una superposición de contornos sobre la imagen. Random Forest conserva principalmente trazos aislados y no reconstruye las ocho siluetas. La visión clásica y SAM 2 mantienen los objetos, aunque difieren en algunos huecos y detalles finos que pueden examinarse en el panel superpuesto.




Figura 17: Cambio del IoU medio entre prueba sintética y capturas reales.

Tabla 6: Repetibilidad del registro por topper en capturas con WCS válido.

Topper	σ_x (mm)	σ_y (mm)	Deriva máx. (mm)
Estrella	0.145	0.163	0.472
Arcoíris	0.158	0.327	0.824
Mariposa	0.262	0.179	0.642
Dinosaurio	0.245	0.320	0.802
Princesa	0.314	0.178	0.780
Unicornio	0.294	0.248	0.630
Camión	0.318	0.252	0.766
Sirena	0.579	0.340	1.647
Promedio global	0.289	0.251	0.820

error angular.

Las desviaciones estándar medias fueron 0,289 mm en X y 0,251 mm en Y. La deriva máxima promedio fue 0,820 mm. La sirena, situada lejos del origen, presentó la mayor deriva. Ese comportamiento es coherente con la propagación de un pequeño error angular, que aumenta con la distancia al WCS. La calibración intrínseca de la cámara y una marca en L de mayor longitud son dos vías directas para reducir este efecto.

7.6. Validación de la cadena software

Las pruebas automatizadas cubrieron cuatro condiciones de integración y finalizaron correctamente. La máscara devuelta por SAM 2 fue la misma que recibió el extractor de contornos. También se verificaron la binarización de la salida, la conservación de componentes por el localizador y el fallo explícito cuando falta el checkpoint. No existe una sustitución silenciosa por la máscara clásica.

La captura 20 se utilizó como prueba de extremo a extremo. El sistema detectó la hoja y los cuatro marcadores, obtuvo un WCS válido, generó ocho prompts, produjo ocho componentes con SAM 2 y extrajo ocho contornos. La exportación resultante fue un DXF de aproximadamente 65,4 kB. La interfaz mostró el modo **SAM 2 + WCS** y habilitó el control de exportación.

7.7. Limitaciones

Los resultados tienen cinco límites. Las trece capturas reales proceden de una sola hoja y la referencia es canónica y asistida. SAM 2 depende de las cajas del localizador clásico. Las identidades se repiten entre particiones sintéticas, aunque no las hojas. La validación llega hasta el DXF y la repetibilidad computacional, sin cortes físicos ni calibración intrínseca.

Pese a ello, las preguntas quedan respondidas. SAM 2 generó máscaras estables para vectorización y mantuvo un IoU alto en las capturas reales, aunque la línea clásica fue superior. El mejor resultado sintético no garantizó transferencia. La salida operativa de SAM 2 permitió integrarlo como motor de la aplicación.

8. Conclusiones y trabajo futuro

Este capítulo relaciona la evidencia experimental con el objetivo general y con cada objetivo específico. También separa los resultados demostrados de las mejoras que requieren nuevas hojas, anotaciones independientes o una campaña física de corte.

8.1. Conclusiones

El trabajo permitió construir y verificar una herramienta que parte de una fotografía real, registra la hoja impresa, segmenta los toppers con SAM 2 y transforma las siluetas en geometría DXF. La propuesta responde al problema observado en Innokey desde un cambio sencillo de proceso: laminar primero la hoja completa sobre el soporte y calcular el corte después, cuando la impresión y el material ya ocupan su posición definitiva.

La primera conclusión es que la inteligencia artificial resulta viable como parte operativa del sistema, aunque no haya sido el método con mayor puntuación real. SAM 2 alcanzó un IoU de 0,9536 sobre las trece capturas y conservó los ocho objetos en todas ellas. Su máscara alimentó la extracción de contornos y la exportación. La prueba sobre la captura 20 terminó con ocho contornos y un DXF válido. Por tanto, la integración de IA no es una comparación aislada ni una opción decorativa de la interfaz.

La segunda conclusión es que un método clásico bien adaptado puede seguir siendo la referencia más fuerte en un montaje controlado. Su IoU real de 0,9787 superó al de SAM 2. El fondo claro, los marcadores conocidos y la cantidad fija de figuras favorecen reglas de color, borde y morfología. Este resultado no se ocultó ni se forzó una ventaja artificial del modelo neuronal. Documentar que la IA no siempre supera a una solución específica forma parte del aporte académico.

La tercera conclusión surge de Random Forest. El modelo seleccionado logró un IoU sintético de 0,9902, el mayor de la prueba, pero descendió a 0,2877 en real. La optimización también mostró que el Jaccard calculado sobre píxeles muestreados puede favorecer un candidato que luego fragmenta la hoja completa. La validación por lámina evitó aceptar ese resultado. En este caso, la brecha sintético-real no es una explicación genérica, sino una diferencia cuantificada de 0,7025 puntos de IoU.

La cuarta conclusión se refiere al registro. Las desviaciones estándar medias de 0,289 mm en X y 0,251 mm en Y indican que la homografía y el WCS proporcionan una base compu-

tacional repetible. La deriva máxima promedio de 0,820 mm también advierte que el error angular crece con la distancia al origen. El resultado es suficiente para justificar la continuación del prototipo, pero no sustituye una medición física del corte.

8.2. Cumplimiento de los objetivos

El objetivo general se considera cumplido dentro del alcance software y computacional definido. La herramienta parte de una fotografía, rectifica la hoja, obtiene ocho máscaras con SAM 2, transforma sus contornos al WCS y genera un DXF cuando la referencia es válida. La captura 20 demostró esa cadena completa con ocho prompts, ocho componentes neuronales y ocho contornos exportables. La comparación con Random Forest y la línea clásica también quedó incorporada a la evaluación, de modo que el uso de IA no se limita a una declaración de diseño.

El cumplimiento no implica que se haya demostrado una reducción de reprocesos en producción. Esa consecuencia pertenece al impacto esperado y necesita cortes físicos, mediciones de borde y comparación con el proceso manual. La Tabla 7 relaciona los objetivos específicos con la evidencia obtenida y mantiene separadas ambas afirmaciones.

Tabla 7: Cumplimiento de los objetivos específicos.

Objetivo	Evidencia principal	Estado
OE1	Procedimiento de captura con teléfono, soporte removible, hoja A4 y trece fotografías bajo variaciones controladas.	Cumplido
OE2	Detección de cuatro marcadores, rectificación a 2100×2970 píxeles y WCS válido en diez capturas.	Cumplido
OE3	Banco de 48 hojas, manifiesto canónico y partición de 36 hojas de entrenamiento, 6 de validación y 6 de prueba.	Cumplido
OE4	Búsqueda aleatoria, 40 ajustes con validación agrupada y selección final del control sin aumentación con umbral 0.70 sobre hojas completas.	Cumplido
OE5	Comparación de cinco prompts, selección de caja con margen del 5 %, evaluación sintética y real e integración de SAM 2 en la GUI.	Cumplido
OE6	Extracción y simplificación de contornos, transformación a milímetros y exportación DXF protegida por WCS.	Cumplido
OE7	Comparación mediante IoU, Dice, Boundary F1, componentes y tiempo, con referencia real asistida y limitaciones declaradas.	Cumplido

8.3. Aportes del trabajo

El TFM deja cuatro aportes concretos. El primero es una arquitectura híbrida donde la geometría clásica registra la escena y un modelo fundacional produce la máscara de uso operativo. El segundo es un protocolo que separa entrenamiento, validación y prueba por hoja y que selecciona Random Forest con una medida coherente con la vectorización. El tercero es una comparación sobre dos dominios con una referencia real que ya no toma la salida clásica como verdad de píxel. El cuarto es una implementación reproducible, acompañada de manifiestos, checksums, pruebas y resultados tabulares.

El hallazgo principal puede resumirse sin contradicciones. Random Forest fue sobresaliente dentro del dominio que aprendió y falló al transferirse. SAM 2 fue menos preciso que Random Forest en sintético, pero mucho más estable en real. La visión clásica obtuvo el mejor resultado real. Pese a ello, SAM 2 demostró calidad suficiente para generar la salida de la aplicación. Cada método aportó una respuesta distinta al problema y la decisión final se apoyó en datos.

8.4. Trabajo futuro

La prioridad siguiente es ampliar el conjunto real. Se requieren varias hojas físicas, diseños no observados, materiales diferentes y anotaciones manuales independientes. Ese banco permitiría estimar generalización y ajustar SAM 2 sin convertir las vistas repetidas de una sola hoja en ejemplos aparentemente independientes.

La segunda línea es mejorar la geometría. Una calibración intrínseca de la cámara reduciría la distorsión antes de la homografía. También conviene aumentar la longitud de la marca WCS y estudiar referencias distribuidas para disminuir la sensibilidad angular en la zona más alejada.

La tercera línea se centra en la IA. Un detector ligero podría sustituir el localizador clásico de cajas y permitir una evaluación neuronal más autónoma. Con un conjunto real suficiente, sería razonable comparar ajuste fino de SAM 2, adaptadores de bajo rango y generación de datos sintéticos más cercana a la cámara. Random Forest podría revisarse con una función de optimización calculada directamente sobre hojas completas, aunque su coste limitaría la cantidad de candidatos.

La cuarta línea es productiva. Debe ejecutarse una campaña de cortes sobre MDF y

acrílico, medir el error entre borde impreso y borde cortado, estimar el ancho real del haz y ajustar la compensación. Solo entonces podrá cuantificarse la reducción de reprocesos, el tiempo de preparación y la aceptación visual por parte del taller.

Finalmente, la aplicación puede optimizarse para uso cotidiano. La inferencia en GPU, la caché del embedding de imagen y un instalador con verificación automática del checkpoint reducirían la fricción. Estas mejoras no cambian el resultado central del TFM, pero acercan el prototipo validado a una herramienta de producción.

ANEXO A.

Repositorio y reproducibilidad

Este apéndice describe cómo reconstruir las evaluaciones y ejecutar la herramienta. El repositorio entregado conserva código, configuraciones, métricas y figuras. Los archivos de modelos de gran tamaño se verifican por nombre, tamaño y SHA-256. Las rutas que contienen datos o checkpoints pueden ajustarse en `software/config/default.yaml`.

A.1. Estructura principal

`memoria/` Fuentes L^AT_EX, bibliografía y figuras de la memoria.

`software/` Aplicación, interfaz gráfica, configuración y pruebas.

`datos/` Manifiesto, particiones, anotaciones y capturas requeridas por los experimentos.

`experimentos/` Scripts de calidad, Random Forest, SAM 2 y comparación.

`resultados/` Métricas CSV/JSON, predicciones, modelos y evidencias de integración.

`documentacion/` Protocolo experimental, calidad de datos y validación técnica.

`output/pdf/` Memoria final compilada.

A.2. Preparación del entorno

En Windows PowerShell, el entorno base puede prepararse con:

```
python -m venv .venv
.\.venv\Scripts\Activate.ps1
python -m pip install --upgrade pip
pip install -r requirements-core.txt
pip install -r requirements-ai.txt
```

La instalación de SAM 2 puede depender de las versiones de Python y PyTorch disponibles. La evaluación final se ejecutó en CPU con Python 3.14.0, PyTorch 2.12.1+cpu,

OpenCV 4.13.0 y scikit-learn 1.9.0. Estos datos también quedan almacenados en los resúmenes JSON. De forma adicional, la cadena completa se reconstruyó en un entorno limpio con Python 3.12 y PyTorch 2.13.0. Esta comprobación independiente procesó la captura 20, recuperó los ocho contornos y generó un DXF válido.

A.3. Modelos utilizados

Tabla 8: Identificación de modelos y checkpoints.

Artefacto	Tamaño	SHA-256
Checkpoint SAM 2 Hiera Tiny	155,906,050 B	65B50056E05BCB13694174F51BB6DA89C894B57B75CCDF0BA6352C597C5D1125
Random Forest selección, sin aumentación	60,111,985 B	B6141FB7DB8320D9A33155F38BFOEFE1AC6FAE15195462548B1D50DDA5627836
Control Random Forest con aumentación	233,889,745 B	4B8D8ED8EE2D7E51C7F93AC50A8E9035AFE1D0BE58462A81E9DB18902E7C3911

La fuente oficial del checkpoint SAM 2 es el repositorio de Meta. Deben respetarse su licencia y las condiciones del proyecto original. Los modelos Random Forest se generan con los scripts y datos de esta entrega. No es necesario conservarlos si se prefiere reconstruirlos.

A.4. Comandos de reproducción

Los comandos siguientes se ejecutan desde la raíz del repositorio:

```
python experimentos/construir_manifiesto.py
```

```
python experimentos/comparacion/crear_referencia_real_asistida.py
```

```
python experimentos/random_forest/optimize_rf.py
```

```
python experimentos/random_forest/refine_rf_on_validation.py
```

```
python experimentos/random_forest/consolidate_rf_selection.py
```

```
python experimentos/sam2/evaluate_sam2.py
```

```
python experimentos/sam2/evaluate_sam2_real.py
```

```
python experimentos/comparacion/evaluate_classical_synthetic.py
python experimentos/comparacion/evaluate_classical_rf_real.py
python experimentos/comparacion/generar_figuras.py
```

```
python -m unittest discover software/tests -v
```

La búsqueda de Random Forest es la etapa de mayor duración. Los archivos finales que justifican la selección contienen:

- el historial de la búsqueda de hiperparámetros.
- la comparación de modelos y umbrales sobre validación.
- la selección consolidada del Random Forest utilizado en prueba.

En SAM 2, la estrategia se registra en `sam2_final_selection.json`.

A.5. Ejecución de la herramienta

La interfaz puede abrirse con:

```
python software/src/gui.py
```

Para una demostración reproducible puede precargarse y procesarse una imagen:

```
python software/src/gui.py --image datos/reales/raw/20.jpg --process
```

La interfaz no vuelve de forma silenciosa al método clásico. Si el checkpoint de SAM 2 no existe o no puede inicializarse, la operación falla con un mensaje. La exportación DXF permanece deshabilitada hasta detectar un WCS válido.

A.6. Publicación

El código fuente, la memoria compilada y los resultados reproducibles están disponibles en el siguiente repositorio público:

<https://github.com/bryangr1993/tfm-vision-artificial-sam2>

Los checkpoints y modelos pesados no forman parte del repositorio ordinario debido a su tamaño. Pueden distribuirse mediante una publicación de GitHub o un almacenamiento externo, siempre acompañados por los checksums de la Tabla 8.

Referencias

- Bhandari, B., y Manandhar, P. (2023). Integrating computer vision and cad for precise dimension extraction and 3d solid model regeneration for enhanced quality assurance. *Machines*, 11(12), 1083. doi: 10.3390/machines11121083
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. doi: 10.1023/A:1010933404324
- Canny, J. (1986). A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-8(6), 679–698. doi: 10.1109/TPAMI.1986.4767851
- Douglas, D. H., y Peucker, T. K. (1973). Algorithms for the reduction of the number of points required to represent a digitized line or its caricature. *Cartographica: The International Journal for Geographic Information and Geovisualization*, 10(2), 112–122. doi: 10.3138/FM57-6770-U75U-7727
- Garrido-Jurado, S., Muñoz-Salinas, R., Madrid-Cuevas, F. J., y Marín-Jiménez, M. J. (2014). Automatic generation and detection of highly reliable fiducial markers under occlusion. *Pattern Recognition*, 47(6), 2280–2292. doi: 10.1016/j.patcog.2014.01.005
- He, K., Gkioxari, G., Dollár, P., y Girshick, R. (2017). Mask r-cnn. En *2017 IEEE international conference on computer vision (iccv)* (pp. 2980–2988). doi: 10.1109/ICCV.2017.322
- Jednorog, R. (2025, 11). A vision-based system for rapid dxf generation in metalworking: Image processing pipeline and economic feasibility case study. *Studia Informatica. System and information technology*, 32, 61–75. doi: 10.34739/si.2025.32.05
- Khafagy, R. R., Eltaib, M. E., y Abo-Shanab, R. F. (2025, 7). Automated complex path extraction and optimization based on scalable vector graphics and genetic algorithm for industrial robot applications. *International Journal of Advanced Manufacturing Technology*, 139, 1033–1052. doi: 10.1007/s00170-025-15846-8
- Kirillov, A., Mintun, E., Ravi, N., Mao, H., Rolland, C., Gustafson, L., ... Girshick, R. (2023). Segment anything. En *Proceedings of the IEEE/CVF international conference on computer vision* (pp. 4015–4026).
- LeCun, Y., Bottou, L., Bengio, Y., y Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278–2324. doi: 10.1109/5.726791

- Li, Q., Zheng, H., Wang, W., y Li, C. (2023, 8). Magnesium ingot stacking segmentation algorithm for industrial robot based on the correction of image overexposure area. *Sensors*, 23. doi: 10.3390/s23156809
- Li, Y., Jin, L., Liu, M., Mo, Y., Zheng, W., Ge, D., y Bai, Y. (2024, 10). Research on adaptive edge detection method of part images using selective processing. *Processes*, 12. doi: 10.3390/pr12102271
- Loganathan, N., Andersson, J., y Patel, V. (2026, 4). Machine vision defect segmentation and geometric measurement for real time quality monitoring in friction stir welding. *Journal of Manufacturing Systems*, 85, 175–192. doi: 10.1016/j.jmsy.2026.01.007
- Martin, D. R., Fowlkes, C. C., y Malik, J. (2004). Learning to detect natural image boundaries using local brightness, color, and texture cues. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 26(5), 530–549. doi: 10.1109/TPAMI.2004.1273918
- Ozkan, M. (2025). Toward automated quality control: An end-to-end image processing and machine learning pipeline for bullet case mouth defect detection. *IEEE Access*, 13, 162764–162778. doi: 10.1109/ACCESS.2025.3610358
- Ravi, N., Gabeur, V., Hu, Y.-T., Hu, R., Ryali, C., Ma, T., ... Feichtenhofer, C. (2025). Sam 2: Segment anything in images and videos. En *International conference on learning representations*. Descargado de https://proceedings.iclr.cc/paper_files/paper/2025/hash/45c1f6a8cbf2da59ebf2c802b4f742cd-Abstract-Conference.html
- Redmon, J., Divvala, S., Girshick, R., y Farhadi, A. (2016). You only look once: Unified, real-time object detection. En *2016 IEEE conference on computer vision and pattern recognition (cvpr)* (pp. 779–788). doi: 10.1109/CVPR.2016.91
- Ronneberger, O., Fischer, P., y Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation. En *Medical image computing and computer-assisted intervention – miccai 2015* (pp. 234–241). Springer. doi: 10.1007/978-3-319-24574-4_28
- Taha, A. A., y Hanbury, A. (2015). Metrics for evaluating 3d medical image segmentation: Analysis, selection, and tool. *BMC Medical Imaging*, 15, 29. doi: 10.1186/s12880-015-0068-x
- Wang, C., Ding, Y., Cui, K., Li, J., Xu, Q., y Mei, J. (2025, 3). A perspective distortion correction method for planar imaging based on homography mapping. *Sensors*, 25. doi: 10.3390/s25061891

- Wang, K., Liu, C., y Shen, S. (2022, 4). Geometric calibration for cameras with inconsistent imaging capabilities. *Sensors*, 22. doi: 10.3390/s22072739
- Zhang, Z. (2000). A flexible new technique for camera calibration. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 22(11), 1330–1334. doi: 10.1109/34.888718